Hugging Face Steam Oyun Veri Seti Üzerinde Veri Ön İşleme Adımlarının Uygulanması

Ahmetcan PEKTAŞ
Bilgisayar Mühendisliği Ana Bilim Dalı YL, Mühendislik Fakültesi, Bandırma Onyedi Eylül Üniversitesi, Balıkesir, Türkiye
ahmetcanpektas@ogr.bandirma.edu.tr

12.10.2026

Hugging Face Steam Oyun Veri Seti Üzerinde Veri Ön İşleme Adımlarının Uygulanması

Özet: Bu çalışmada, web kazıma yoluyla derlenmiş 125.855 oyun ve 40 değişkenden oluşan Steam Games Dataset üzerinde veri ön işleme adımları sistematik olarak uygulanmıştır. Süreç; değişken tiplerinin belirlenmesi, veri kalitesinin değerlendirilmesi, temizleme, eksik veri analizi, aykırı değer yönetimi, tekrarlı, tutarsız ve gürültülü kayıtların ele alınması, dönüşüm ve ölçekleme, keşifsel veri analizi, özellik mühendisliği ve seçimi ile sızıntısız bir veri setinin hazırlanmasını kapsamaktadır. Tüm kolonları sessizce kaydıran hatalı başlık satırı ile boş liste ve yapısal sıfır olarak kodlanmış gizli eksik değerler en kritik kalite sorunları olarak belirlenmiştir. Metacritic puanlarındaki eksikliğin rastgele olmadığı (MAR) saptanmış ve satırlar silinmek yerine eksiklik bir gösterge değişkeniyle korunmuştur. Temizleme sonrasında 117.521 kayıt kalmış, 38 yeni özellik türetilmiş ve 51 aday özellikten 41'i seçilmiştir. Bir oyunun yalnızca yayın öncesi mağaza bilgileriyle beğenilip beğenilmeyeceğinin tahmininde Random Forest modeli 0,754 test ROC-AUC (F1 = 0,707) değerine ulaşırken, yayın sonrası değişkenlerin modele eklenmesi ROC-AUC değerini yapay olarak 1,000'e yükseltmiştir. Bu sonuçlar, fark edilmeyen kalite sorunlarının ve veri sızıntısının kod hata vermeden yanıltıcı sonuçlar üretebileceğini göstermektedir.

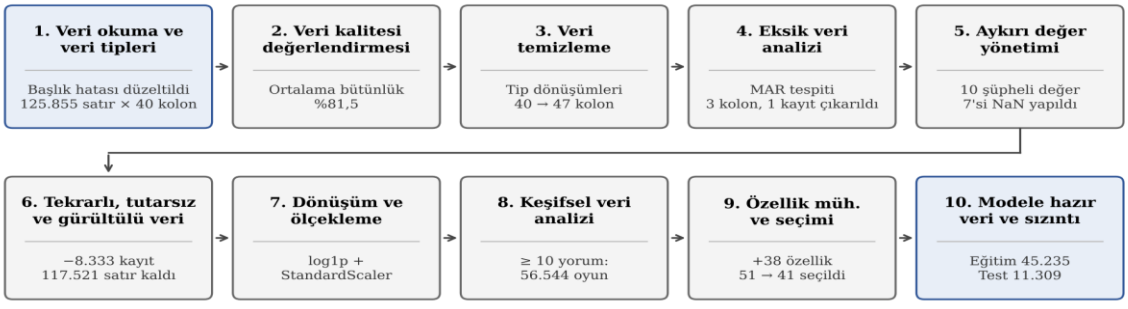
1. Veri Seti

Çalışmada, Hugging Face platformunda kamuya açık olarak sunulan Steam Games Dataset kullanılmıştır. Veri seti, Steam Store API ve SteamSpy servislerinden kazınan 125.855 oyuna ait 40 değişken içermektedir. Değişkenler; fiyat, çıkış tarihi, desteklenen diller, tür ve kategoriler, yorum sayıları, tahmini sahip sayısı ve oynama süreleri gibi bilgileri kapsamaktadır. Tahmini sahip sayısı ve oynama sürelerinin doğrudan ölçüm değil, SteamSpy örneklemesine dayalı tahminler olduğu dikkate alınmıştır. Değişkenler ölçme düzeylerine göre sınıflandırılmış ve her grup için uygulanan işlemler Tablo 1'de özetlenmiştir.

Tüm işlemler Python ortamında pandas ve scikit-learn kütüphaneleri kullanılarak Google Colab üzerinden gerçekleştirilmiş, tekrarlanabilirlik için rastgele tohum değeri 42 olarak sabitlenmiştir. Ön işleme adımlarının etkisini değerlendirmek amacıyla, bir oyunun yalnızca yayın öncesinde bilinen mağaza sayfası bilgilerine dayanarak oyuncular tarafından beğenilip beğenilmeyeceğinin tahmin edildiği basitçe bir sınıflandırma senaryosu tanımlanmıştır. Olumlu yorum oranı 0,80 ve üzerinde olan oyunlar "beğenilen" sınıfına atanmıştır. Sınıflandırıcı olarak Lojistik Regresyon ve Random Forest seçilmiş, performans ROC-AUC ve F1 skoru ile ölçülmüştür.

2. Veri Ön İşleme Süreci

Uygulanan veri ön işleme süreci on adımdan oluşmaktadır. Adımların sırası ve her adımın veri üzerindeki temel etkisi Şekil 1'de özetlenmiştir. Bu bölümde her adımda yapılan işlemler, alınan kararlar ve bu kararların gerekçeleri sırasıyla açıklanmaktadır.



Şekil 1. Uygulanan veri ön işleme sürecinin adımları ve her adımın veri üzerindeki temel etkisi.

2.1. Veri Okuma ve Veri Tiplerinin Belirlenmesi

Veri seti okunurken başlık satırında 39, veri satırlarında ise 40 alan bulunduğu tespit edilmiştir. Bu uyuşmazlığın, başlıkta Discount ve DLC count kolonlarının "DiscountDLC count" biçiminde birleşmesinden kaynaklandığı belirlenmiştir. Dosya doğrudan okunduğunda tüm kolonlar bir konum kaymakta; örneğin Name kolonunda tarihler, Price kolonunda ise yaş sınırı değerleri yer almaktadır. Kod herhangi bir hata vermediği için bu sorunun fark edilmeden analize devam edilmesi mümkündür. Sorun, başlık satırı iki ayrı kolon adıyla yeniden tanımlanarak giderilmiştir.

Ardından pandas'ın atadığı teknik veri tipleri ile değişkenlerin anlamı karşılaştırılmıştır. Örneğin çıkış tarihi ve tahmini sahip sayısı metin olarak, desteklenen diller ise Python listesinin metne dökülmüş hâli olarak okunmuştur. Değişkenler ölçme düzeylerine göre sınıflandırılmış ve her grup için uygulanacak işlem belirlenmiştir (Tablo 1).

Tablo 1. Değişken gruplarının ölçme düzeyleri ve uygulanan işlemler.

Değişken grubu	Örnek değişkenler	Ölçek	Uygulanan işlem
Sayım ve parasal	Price, Positive, Peak CCU, DLC count	Oran	log1p dönüşümü, ölçekleme
Tarih	Release date	Aralık	Yıl, ay ve oyun yaşı türetme
Aralık kategorisi	Estimated owners	Ordinal	Alt/üst sınır ve orta nokta
Çok etiketli liste	Genres, Categories, Supported languages	Nominal	Multi-hot kodlama, etiket sayısı
Yüksek kardinaliteli	Developers, Publishers	Nominal	Yazım standardizasyonu, frekans kodlama
Puan	Metacritic score, User score	Aralık	0 → eksik, gösterge değişkeni
Metin ve URL	About the game, Website, Screenshots	–	Uzunluk/sayı türetme, kolonu çıkarma

Toplam 40 değişken: 12 nominal, 12 oran, 3 ordinal, 2 aralık, 1 aralık/oran ve 10 metin/URL.

2.2. Veri Kalitesinin Değerlendirilmesi

Veri kalitesi bütünlük, geçerlilik, tutarlılık ve teklik boyutlarında değerlendirilmiştir. Bütünlük ölçülürken yalnızca NaN değerler değil, boş metinler ve boş listeler ("[]") de eksik kabul edilmiştir. Bu yaklaşımla Full audio languages kolonunun pandas'a göre %0 olan eksiklik oranının gerçekte %59,3 olduğu ortaya çıkmıştır. Tüm kolonlar dikkate alındığında ortalama bütünlük %81,5 olarak hesaplanmıştır.

Geçerlilik için fiyatın negatif olmaması, indirim ve Metacritic puanının 0–100 aralığında olması, yaş sınırının 0–21 aralığında olması ve tarihin ayrıştırılabilir olması gibi kurallar tanımlanmıştır. Bu kurallarda yalnızca bir oyunun çıkış tarihinin gelecekte olduğu görülmüştür. Tutarlılık kontrollerinde ise 367 oyunda son iki haftalık oynama süresinin toplam süreden büyük olduğu ve 39 ücretsiz oyunda indirim tanımlandığı belirlenmiştir. Tekrarlı AppID veya tamamen aynı satır bulunmamıştır. Bu tutarsızlıklar, verilerin farklı zamanlarda ve farklı kaynaklardan kazınmasının bir sonucu olarak yorumlanmıştır.

2.3. Veri Temizleme Adımı

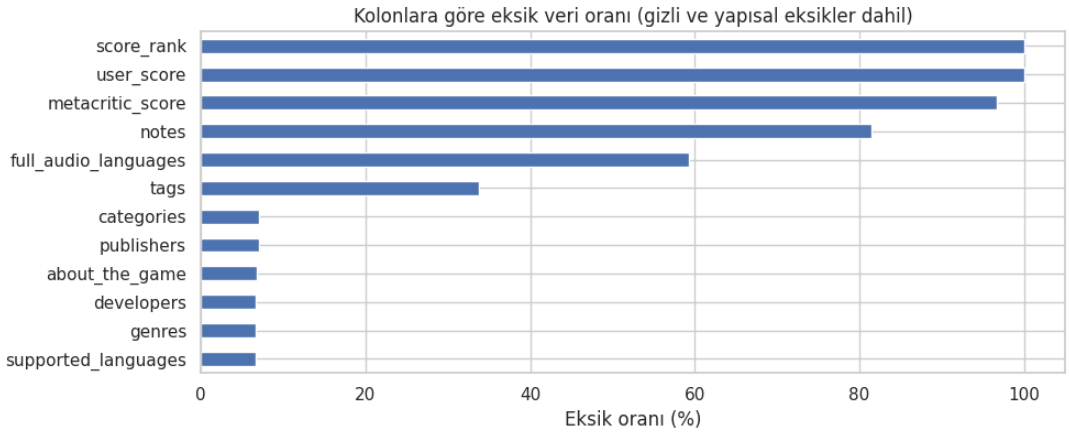
Bu aşamada, metinsel değişkenlerdeki gereksiz boşluklar temizlenmiş ve boş değerler `NaN` olarak tanımlanmıştır. Yayın tarihleri `datetime` tipine dönüştürülmüş, tahmini sahiplik aralıklarından alt sınır, üst sınır ve aralık orta değeri hesaplanmıştır. Dil, tür, kategori, etiket, geliştirici ve yayıncı bilgileri Python liste yapısına dönüştürülmüştür. URL değişkenlerinden ekran görüntüsü sayısı, video sayısı ve iletişim bilgisi varlığı gibi yeni özellikler türetilerek ilgili sütunlar kaldırılmıştır. Ayrıca %90'ı eksik olan `Reviews` sütunu çıkarılmış ve sütun adları `snake_case` biçiminde standartlaştırılmıştır. Bu işlemler sonucunda sütun sayısı 40'tan 47'ye yükselmiştir.

2.4. Eksik Veri Analizi ve Yönetimi

Bu aşamada, eksik değerler ve eksikliği temsil eden sıfır değerleri incelenmiştir. Metacritic ve kullanıcı puanlarındaki 0 değerleri NaN olarak tanımlanmış, eksiklik oranları sırasıyla %96,6 ve %99,97 olarak hesaplanmıştır

(Şekil 2). Metacritic puanı bulunan oyunların medyan yorum sayısı 1.482, bulunmayanların ise 5 olarak belirlenmiştir. Bu farklılık, eksikliğin oyun popülerliğiyle ilişkili olabileceğini göstermektedir. Eksiklik bilgisi has_metacritic ve has_user_score değişkenleriyle korunmuş; %95'in üzerinde eksik veri içeren üç sütun kaldırılmıştır. notes değişkeninde yaklaşık %81, full_audio_languages değişkeninde %59 ve tags değişkeninde %34 oranında eksik veri bulunmaktadır. Diğer kategorik değişkenlerde ise eksiklik oranları %7'nin altındadır. Yüksek eksiklik oranına sahip puan değişkenleri analizden çıkarılmış, diğer değişkenlerdeki eksiklikler veri türü ve kullanım amacı doğrultusunda değerlendirilmiştir.

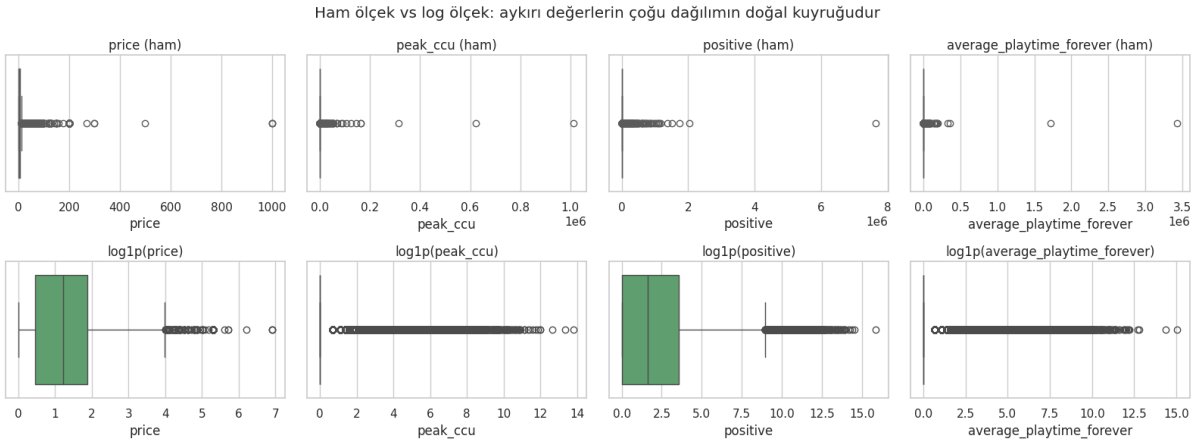
Kategorik eksikler Unknown ile doldurulmuş ve oyun adı bulunmayan bir kayıt silinmiştir. Sayısal eksiklerin medyanla doldurulması ise veri sızıntısını önlemek amacıyla eğitim/test ayrımından sonraya bırakılmıştır.



Şekil 2. Gizli ve yapısal eksikler dahil edildikten sonra kolonlara göre eksik veri oranları.

2.5. Aykırı Değer Tespiti ve Yönetimi

Aykırı değerler, sekiz sayısal değişkende çeyrekler açıklığı (IQR, k = 1,5) ve z-skor (|z| > 3) yöntemleriyle ham ve logaritmik ölçekte tespit edilmiştir. Bu değişkenler sağa çarpıktır (çarpıklık katsayısı 22–266) ve IQR yöntemi ham ölçekte binlerce gözlemi aykırı olarak işaretlemiştir. Ancak Şekil 3'te görüldüğü üzere bu gözlemler ölçüm hatası değil, ağır kuyruklu (heavy-tailed) dağılımın doğal bir sonucudur. Nitekim olumlu yorum sayısında aykırı gözlem sayısı log dönüşümüyle 21.288'den 1.789'a düşmüştür. Bu nedenle söz konusu gözlemler silinmemiş, dönüşümle ele alınmıştır (Bölüm 2.7).



Şekil 3. Seçilen değişkenlerin ham ölçekte (üst) ve log1p dönüşümü sonrasında (alt) kutu grafikleri.

Hatalı değerleri ayırt etmek için alan bilgisine dayalı eşikler tanımlanmıştır: fiyat > 500 $, ortalama oynama süresi > 20.000 saat, başarım sayısı > 5.000 ve DLC sayısı > 1.000. Bu eşiklerle belirlenen 10 şüpheli değerden gerçekçi olmayan 7'si (ör. 999 $ fiyat, ~57.000 saat oynama süresi) eksik değer (NaN) olarak işaretlenmiştir. Yüksek DLC sayıları ise gerçek gözlem olarak değerlendirilip korunmuştur. Alternatif yöntem olarak fiyat

değişkenine %1–%99 yüzdelik sınırlarıyla winsorizing uygulanmıştır (0–29,99 $). Değerlerin çoğunluğu sıfır olan (zero-inflated) değişkenlerde ise IQR sıfıra eşit çıktığından yöntemin uygulanabilir olmadığı görülmüştür.

2.6. Tekrarlı, Tutarsız ve Gürültülü Verinin Ele Alınması

Tekrarlı kayıt analizinde AppID ve tüm sütunlar bazında tekrar bulunmamış, ancak oyun adı, yayın tarihi ve geliştirici bilgileri karşılaştırılarak 111 tekrarlı kayıt tespit edilmiş ve kaldırılmıştır. Geliştirici adlarındaki yazım farklılıkları standartlaştırılmış ve 1.996 geliştiricinin farklı biçimlerde kaydedildiği belirlenmiştir. Oynama sürelerinde tutarsızlık bulunan 366 kayıt düzeltilmiş, ücretsiz olmasına rağmen indirim tanımlanan 37 oyunun indirim değeri sıfırlanmıştır. Oynama süreleri dakikadan saate dönüştürülmüştür. Son olarak, çalışma kapsamı dışında değerlendirilen demo, playtest, test sunucusu ve oyun müziği içerikli 8.222 kayıt çıkarılmıştır. Bu işlemlerin veri setinin büyüklüğüne etkisi Tablo 2'de sunulmuştur.

Tablo 2. Ön işleme adımlarının kayıt sayısına etkisi.

Adım	Çıkarılan kayıt	Kalan kayıt
Ham veri	–	125.855
İsimsiz kayıtlar (Bölüm 2.4)	1	125.854
Tekrarlı kayıtlar (aynı ad, tarih ve geliştirici)	111	125.743
Playtest, demo ve film müziği kayıtları	8.222	117.521
Modelleme kümesi (en az 10 yorum, Bölüm 2.10)	60.977	56.544

2.7. Veri Dönüşümü, Ölçekleme ve Normalizasyon

Çarpık dağılıma sahip değişkenlere log1p ve Yeo-Johnson dönüşümleri uygulanarak sonuçlar karşılaştırılmıştır (Tablo 3). Yeo-Johnson yöntemi çarpıklığı daha fazla azaltmasına rağmen, veri üzerinden parametre öğrenmemesi, veri sızıntısı riski oluşturmaması ve yorumlanabilirliği nedeniyle log1p dönüşümü tercih edilmiştir.

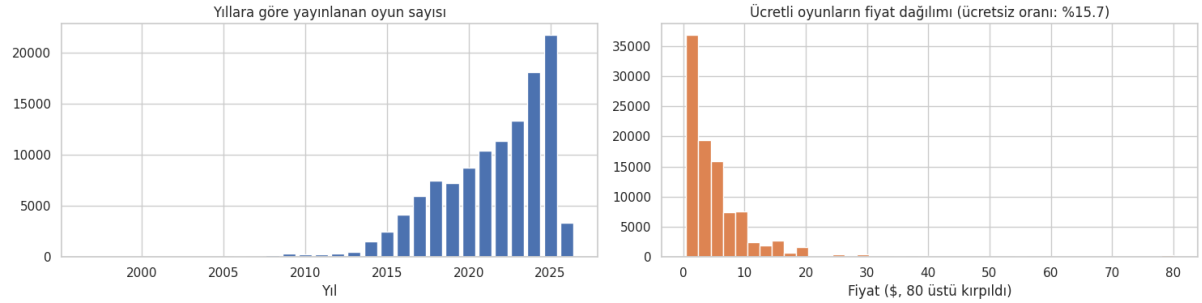
Tablo 3. Çarpık değişkenlerde dönüşüm öncesi ve sonrası çarpıklık katsayıları.

Değişken	Ham	log1p	Yeo-Johnson
Price	12,72	0,41	0,03
Positive	178,87	1,05	0,21
Negative	157,69	1,41	0,39
Peak CCU	206,33	4,34	1,82
Achievements	31,35	0,32	0,13
Ortalama oynama süresi (saat)	74,05	2,78	1,49
Estimated owners (orta nokta)	70,96	-1,63	0,21

Ölçekleme aşamasında StandardScaler, MinMaxScaler ve RobustScaler yöntemleri logaritmik dönüşüm uygulanmış fiyat değişkeni üzerinde karşılaştırılmıştır. StandardScaler ortalama ve standart sapmayı, MinMaxScaler minimum ve maksimum değerleri, RobustScaler ise medyan ve IQR değerlerini esas almaktadır. Log dönüşümü sonrasında çarpıklığın azalması nedeniyle StandardScaler tercih edilmiştir. Veri sızıntısını önlemek amacıyla ölçekleyici yalnızca eğitim verisi üzerinde öğrenilmiş ve test verisine aynı parametreler uygulanmıştır.

2.8. Keşifsel Veri Analizi (EDA)

Şekil 4'e göre Steam'de yayımlanan oyun sayısı yıllar içinde artarak 2025'te yaklaşık 21.700 ile en yüksek seviyeye ulaşmıştır. Bu artış, farklı dönemlerde yayımlanan oyunların veri dağılımlarının değişebileceğini göstermektedir. Oyunların %15,7'si ücretsizdir ve medyan fiyat 2,39 dolardır. Veri setinde en yaygın oyun türleri Indie, Casual, Action ve Adventure olarak belirlenmiştir.



Şekil 4. Yıllara göre yayımlanan oyun sayısı (sol) ve ücretli oyunların fiyat dağılımı (sağ).

Oyunların %29,5'inin kullanıcı yorumu almadığı belirlenmiştir. Olumlu yorum oranının daha güvenilir hesaplanabilmesi için hedef değişken en az 10 yorum alan oyunlarla sınırlandırılmıştır. Bu oyunlarda sınıf dağılımı %53,5 olumlu ve %46,5 olumsuzdur. Spearman korelasyon analizinde yorum, tavsiye, sahiplik ve eşzamanlı oyuncu sayıları arasında güçlü ilişkiler tespit edilmiştir. Fiyat ile olumlu yorum oranı arasında ise belirgin bir ilişki bulunmamıştır.

2.9. Özellik Mühendisliği ve Özellik Seçimi

Özellik mühendisliği aşamasında ham verilerden 38 yeni özellik türetilmiştir. Bunlar arasında oyunun çıkış tarihi ve yaşı, dil desteği, tür ve kategori sayıları, açıklama uzunluğu, fiyat ve DLC bilgileri ile platform, çok oyunculu, bulut kaydı, kontrolcü ve VR desteği bulunmaktadır. En yaygın 15 oyun türü multi-hot encoding yöntemiyle, geliştirici bilgileri ise yayımlanan oyun sayısına dayalı frekans kodlamasıyla sayısallaştırılmıştır.

Özellik seçiminde varyans eşiği (0,01), korelasyon filtresi ($|r| > 0{,}90$) ve karşılıklı bilgi (mutual information) yöntemleri uygulanmıştır. Varyans analiziyle düşük değişkenlik gösteren 5 özellik, korelasyon analiziyle yüksek ilişkili 2 özellik ve karşılıklı bilgi analiziyle hedef değişkenle ilişkisi düşük 3 özellik elenmiştir. Böylece 51 aday özellikten 41'i modelleme için seçilmiştir.

2.10. Modele Hazır Veri Seti ve Veri Sızıntısının Önlenmesi

En az 10 yorum alan 56.544 oyun, sınıf dağılımı korunarak %80 eğitim (45.235) ve %20 test (11.309) olarak ayrılmıştır. Hedef değişken yorum sayılarından türetildiği için olumlu ve olumsuz yorum sayıları modelden çıkarılmıştır. Ayrıca çalışma yayın öncesi tahmine odaklandığından, tavsiye ve sahiplik sayıları, eşzamanlı oyuncu sayısı, oynama süreleri ve Metacritic puanı gibi yayın sonrasında oluşan değişkenler hedef sızıntısını önlemek amacıyla kullanılmamıştır.

Eksik değerlerin medyanla doldurulması ve ölçekleme işlemleri, veri sızıntısını önlemek amacıyla Pipeline içerisinde yalnızca eğitim verisinden öğrenilen parametrelerle gerçekleştirilmiştir. Ölçekleyicinin tüm veri üzerinde eğitilmesi durumunda hesaplanan ortalamaların farklılaştığı görülmüş ve bunun test verisinden bilgi sızmasına neden olabileceği değerlendirilmiştir. Son olarak temizlenmiş veri seti ile 56.544 gözlem, 41 özellik ve hedef değişkenden oluşan modellemeye hazır veri seti ayrı dosyalara kaydedilmiştir.

3. Bulgular

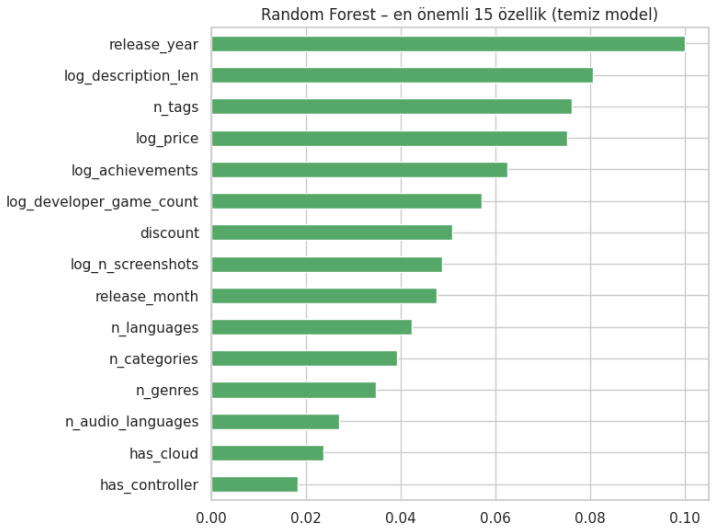
Veri ön işleme ve hedef sızıntısının model performansına etkisini değerlendirmek amacıyla, yalnızca yayın öncesi bilgileri içeren temiz özellik seti ile yayın sonrası bilgilerin de kullanıldığı sızıntılı özellik seti karşılaştırılmıştır (Tablo 4). Temiz veri setinde Random Forest modeli 0,754 ROC-AUC ve 0,707 F1-skoru, Lojistik Regresyon ise 0,705 ROC-AUC ve 0,673 F1-skoru elde etmiştir.

Tablo 4. Temiz ve sızıntılı özellik setleriyle elde edilen test performansı.

Model	Özellik seti	ROC-AUC	F1-skoru
Random Forest	Temiz	0,754	0,707
Lojistik Regresyon	Temiz	0,705	0,673
Random Forest	Sızıntılı	1,000	1,000
Lojistik Regresyon	Sızıntılı	1,000	0,997

Random Forest: 300 ağaç, dengeli sınıf ağırlıkları. Her iki model aynı Pipeline ile eğitilmiştir.

Sızıntılı veri setinde her iki modelin ROC-AUC değeri 1,000'e ulaşmıştır. Sızıntılı veri setindeki kusursuza yakın sonuçlar, gerçek tahmin başarısından ziyade hedef değişkenle doğrudan ilişkili bilgilerin kullanılmasından kaynaklanmaktadır. Yayın öncesi bilgilerle eğitilen Random Forest modeli ise %68,3 doğruluk elde etmiştir. Özellik önem analizinde çıkış yılı, açıklama uzunluğu, etiket sayısı, fiyat ve başarım sayısı öne çıkmıştır (Şekil 5). Bu bulgular, veri sızıntısının önlenmesinin güvenilir model değerlendirmesi açısından önemini göstermektedir.



Şekil 5. Temiz Random Forest modelinde en önemli 15 özellik.

4. Tartışma ve Sonuç

Çalışma, veri setindeki eksik, hatalı ve tutarsız değerlerin analiz sonuçlarını önemli ölçüde etkileyebileceğini göstermiştir. Eksik ve aykırı değerlerin doğrudan silinmesi yerine uygun dönüşüm ve düzeltme yöntemlerinin kullanılmasıyla veri kaybı sınırlandırılmıştır. Özellikle veri sızıntısı deneyinde elde edilen sonuçlar, doğru ön işleme yöntemlerinin güvenilir model değerlendirmesi açısından önemini ortaya koymuştur.

Çalışmanın başlıca sınırlılıkları, bazı değişkenlerin tahmini verilere dayanması, veri setinin tek bir zaman dilimini temsil etmesi ve rastgele eğitim/test ayrımı kullanılmasıdır. Gelecek çalışmalarda zamana dayalı veri ayrımıyla modellerin yeni oyunlar üzerindeki başarısının değerlendirilmesi önerilmektedir.

Bu çalışmada Steam Games Dataset üzerinde on aşamalı veri ön işleme süreci uygulanmıştır. Eksik ve tutarsız veriler düzenlenmiş, aykırı değerler analiz edilmiş ve log1p dönüşümüyle çarpıklık azaltılmıştır. Tekrarlı ve kapsam dışı 8.334 kayıt çıkarılmış, 38 yeni özellik türetilmiş ve 51 aday özellikten 41'i seçilmiştir. Temiz veri setiyle eğitilen Random Forest modeli 0,754 ROC-AUC değerine ulaşırken, veri sızıntısı içeren modelde bu değer yapay olarak 1,000'e yükselmiştir. Sonuçlar, veri ön işleme ve sızıntı kontrolünün güvenilir makine öğrenmesi modelleri geliştirmedeki önemini ortaya koymaktadır.